

Relatório: Associação entre Glicemia e IMC - Disciplina de Modelos Estatísticos /IMPA Tech

Eliani Magalhães Beloni

2026-09-26

1. Análise Descritiva e Bivariada

Para compreender o perfil dos 142 adultos da amostra e antecipar os fatores associados aos níveis de glicemia em jejum (**glicemia**), realizou-se uma análise exploratória abrangendo o comportamento individual de cada variável (univariada) e a relação da variável resposta com as explicativas (bivariada).

Principais Resultados

- **Análise Univariada**

- **Glicemia (**glicemia**)**: Apresenta ampla variação (entre 70 e 180 mg/dL), cobrindo faixas desde a euglicemia até a hiperglicemia.
- **IMC (**imc**)**: Concentra-se predominantemente entre 24 e 28 kg/m², indicando alta proporção de indivíduos com sobrepeso.
- **Condições Categóricas**: Predominam participantes sem diagnóstico de hipertensão (72,5%) e sem histórico familiar de *Diabetes Mellitus* (62,7%).

- **Análise Bivariada (Relação com a Glicemia):**

- **IMC**: Mostra uma **forte relação linear positiva** (maior IMC está associado a níveis mais elevados de glicemia em jejum).
- **Atividade Física**: Exibe uma **relação linear negativa** (maior tempo semanal de atividade física atua como fator associado a menores níveis glicêmicos).
- **Idade**: Não apresenta tendência linear expressiva em relação à glicemia nesta amostra.
- **Sexo, Hipertensão e Histórico Familiar**: Apresentam distribuições de glicemia relativamente semelhantes entre suas categorias quando analisados de forma isolada.

Os gráficos detalhados das distribuições e das relações bivariadas com a glicemia encontram-se apresentados a seguir.

Sumário Estatístico


Tabela 1: Resumo das variáveis numéricas

Variável	Média	DP	Mín	Mediana	Máx
Glicemia (mg/dL)	121.2	30.7	70	119.0	180.0
IMC (kg/m ²)	26.8	3.3	20	26.4	35.4
Idade (anos)	43.2	12.1	20	42.5	75.0
Atividade física (min/sem)	147.5	67.9	2	146.5	303.0


Tabela 2: Resumo das variáveis categóricas

Variável	Categoria	n	%
Sexo	Feminino	87	61.3
Sexo	Masculino	55	38.7
Histórico familiar	Não	89	62.7
Histórico familiar	Sim	53	37.3
Hipertensão	Não	103	72.5
Hipertensão	Sim	39	27.5

Análise Univariada (Distribuições)



Análise Bivariada (Relações com a Glicemia)



2. Verificação de Multicolinearidade

Para verificar a presença de multicolinearidade entre as variáveis explicativas, utiliza-se o **Fator de Inflação da Variância (VIF)**.

Os valores obtidos situaram-se todos entre 1,02 e 1,12, muito próximos do valor ideal de 1,0. Como

todos os valores são inferiores ao limite adotado na literatura ($VIF < 5$), conclui-se que **não existe multicolinearidade** entre os preditores no modelo ajustado.

Tabela 3: Fator de Inflação da Variância (VIF) do modelo completo

	VIF
imc	1.12
idade	1.02
atividade_fisica	1.11
sexo	1.07
historico_familiar	1.07
hipertensao	1.05

3. Ajuste e Comparação de Modelos Lineares

A construção do modelo seguiu uma estratégia **sequencial**, partindo da variável de maior interesse (**imc**) e adicionando demais covariáveis uma a uma, testando a cada passo (via `anova()`, teste F para modelos aninhados) se a inclusão melhora significativamente o ajuste.

Tabela 4: Construção sequencial do modelo: AIC, BIC, R^2 ajustado e teste F de cada incremento

Passo	AIC	BIC	R^2 Adj (%)	p-valor (vs. anterior)
1. imc	1351.18	1360.05	17.88	NA
2. + atividade_fisica	1322.33	1334.16	33.44	0.0000
3. + imc:atividade_fisica	1320.93	1335.71	34.54	0.0696
4. + idade	1324.32	1339.10	32.96	0.9130
5. + sexo	1325.62	1343.36	32.81	0.4124
6. + historico_familiar	1327.56	1348.25	32.34	0.8031
7. + hipertensao	1329.26	1352.91	31.98	0.5993

A inclusão do termo de interação (**imc:atividade_fisica**) não apresentou significância estatística ao nível de 5% ($p = 0,0696$). De forma análoga, nenhuma das demais covariáveis adicionadas subsequentemente (idade, sexo, histórico familiar e hipertensão) melhorou o ajuste do modelo, apresentando p-valores elevados (todos acima de 0,41). Adicionalmente, os critérios AIC e BIC pioraram progressivamente a cada inclusão. Portanto, o modelo final manteve-se apenas com os efeitos principais **imc + atividade_fisica**.


Modelo Final

Tabela 5: Estimativas do modelo final (glicemia $\sim$ imc + atividade_fisica)

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	70.002	19.857	3.525	0.001

	Estimate	Std. Error	t value	Pr(> t)
imc	2.946	0.669	4.406	0.000
atividade_fisica	-0.188	0.032	-5.807	0.000

O modelo final apresentou $R^2 = 34.4\%$ e R^2 ajustado = 33.4%, indicando que o `imc` e a `atividade_fisica` explicam juntos cerca de um terço da variabilidade da glicemia em jejum nesta amostra. O erro padrão residual foi de 25 mg/dL.




Por que não testar interações adicionais

Não foi encontrada justificativa para testar produtos entre variáveis (termos de interação) além do que já foi testado. Idade, sexo, histórico familiar e hipertensão, quando adicionadas ao modelo uma a uma, não tiveram efeito relevante sobre a glicemia ($p > 0.41$ em todos os casos, ver tabela 4). Como nenhuma dessas variáveis mostrou efeito nem de forma simples, não faz sentido testar interações envolvendo elas. A única interação com justificativa teórica, `imc:atividade_fisica`, também não foi significativa ($p = 0.0696$). Testar mais interações sem essa base aumentaria o risco de achar resultados por acaso, sem ganho real de explicação. Por isso o modelo final permanece **`glicemia ~ imc + atividade_fisica`**.

4. Análise de Resíduos e Suposições do Modelo Final



Normalidade dos Resíduos

Normal Q-Q Plot dos resíduos padronizados



O teste de Shapiro-Wilk resultou em $W = 0.984$ e $p\text{-valor} = 0.0937$, **não rejeitando** a hipótese de normalidade dos resíduos a 5%. O gráfico Q-Q, no entanto, mostra um leve desvio da reta teórica nas caudas (pontos mais extremos, tanto positivos quanto negativos, ficam ligeiramente acima/abaixo da reta), sugerindo caudas um pouco mais pesadas que a distribuição normal. Como o teste formal não indicou violação significativa e o desvio visual é discreto, concluímos que a suposição de normalidade é **razoavelmente atendida**, sem comprometer de forma relevante a validade das inferências do modelo.

Homocedasticidade e Independência



O gráfico de resíduos vs. valores ajustados não mostra padrão sistemático (sem funil, sem curvatura), sustentando a homocedasticidade.

Já o gráfico de resíduos vs. ordem dos dados exibe blocos alternados de resíduos positivos e negativos. Essa oscilação sistemática decorre diretamente da estrutura da variável idade: ao analisar o gráfico de dispersão entre idade e glicemia, observa-se a presença de um padrão sintético não linear (o

artefato geométrico do *Datasaurus Dozen*). Como as observações foram registradas no arquivo seguindo a trajetória do contorno dessa figura, a ordem dos dados reflete a variação espacial dos pontos em relação à reta de regressão. Isso demonstra que a falta de aleatoriedade nos resíduos não se deve a uma falha temporal de coleta, mas sim à tentativa do modelo linear de ajustar uma reta a uma estrutura puramente não linear.

Pontos Influentes



Tabela 6: Observações sinalizadas por pelo menos uma medida de influência

	dfb.1	dfb.imc	dfb.atv	dffit	cov.r	cook.d	hat
8	-0.068	0.075	0.016	0.082	1.071	0.002	0.048
26	-0.061	0.060	0.038	0.069	1.074	0.002	0.050
72	0.281	-0.285	-0.016	0.352	0.933	0.040	0.023
83	-0.359	0.362	0.192	0.393	1.058	0.051	0.074
85	-0.031	0.040	-0.011	0.050	1.066	0.001	0.043
119	-0.342	0.243	0.428	-0.488	0.956	0.077	0.044
122	0.031	-0.016	-0.088	-0.096	1.066	0.003	0.045
141	-0.035	0.048	-0.026	0.067	1.088	0.001	0.062

A Tabela 6 detalha as observações sinalizadas por pelo menos uma medida de influência:

- **Efeito na Precisão (*COVRATIO*):** Os pontos **#8**, **#26**, **#85**, **#122** e **#141** foram indicados apenas pela alteração na variância ($\text{cov.r} > 1,063$), sem impacto na reta ajustada ($\text{Cook.D} \leq 0,003$).

- **Desvios Locais ($DFBETAS$ / $DFFITs$):** As maiores oscilações pontuais ocorreram nos pontos **#83** (maior impacto no coeficiente do IMC, $dfb.imc = 0,362$) e **#119** (maior desvio na predição, $df fit = -0,488$).
- **Influência Global ($Cook.D$):** A maior distância de Cook registrada foi 0,077 (ponto **#119**), valor expressivamente inferior ao limite crítico (0,8).

Portanto, nenhuma observação atua como ponto influente prejudicial, garantindo a estabilidade das estimativas do modelo.

5. Equação do Modelo Final e Interpretação

O modelo final ajustado foi:

$$\widehat{\text{Glicemia}} = 70 + 2.95 \cdot \text{IMC} - 0.1875 \cdot \text{Atividade física}$$

onde **Glicemia** é medida em mg/dL, **IMC** em kg/m², e **Atividade física** em minutos semanais de atividade moderada.

Interpretação do efeito do IMC: Mantendo constante o tempo de atividade física, cada aumento de 1 kg/m² no IMC está associado, em média, a um aumento de 2.95 mg/dL na glicemia em jejum (IC 95%: 1.62 a 4.27 mg/dL). Como o intervalo de confiança não inclui o zero, esse efeito é estatisticamente significativo. Em termos práticos, um aumento de 5 pontos no IMC (por exemplo, saindo de um IMC de 25 para 30, uma mudança de sobrepeso para obesidade) corresponderia a um acréscimo médio de aproximadamente 14.7 mg/dL na glicemia, controlando pelo nível de atividade física.

6. Comparação do Efeito do IMC (Modelo Simples vs. Modelo Final)

Tabela 7: Comparação do efeito do IMC entre o modelo simples e o modelo final

Modelo	Coefficiente do IMC	IC 95% inferior	IC 95% superior
Simples (glicemia ~ imc)	4.019	2.608	5.430
Final (glicemia ~ imc + atividade_fisica)	2.946	1.624	4.268

No modelo simples, cada aumento de 1 kg/m² no IMC está associado a um aumento médio de 4.02 mg/dL na glicemia. Já no modelo final, controlando pela atividade física, esse efeito passa a ser 2.95 mg/dL, uma redução de aproximadamente 26.7% em relação ao modelo simples.

Essa mudança sugere que parte da associação observada entre IMC e glicemia no modelo simples é parcialmente explicada pelo nível de atividade física (um possível confundidor): há uma correlação negativa entre IMC e atividade física nesta amostra ($r = -0.28$, $p = 8.72 \times 10^{-4}$). Ainda assim, o efeito do IMC permanece estatisticamente significativo em ambos os modelos (os intervalos de confiança não cruzam o zero em nenhum dos dois casos), reforçando que o IMC tem uma associação própria e relevante com a glicemia, independentemente do nível de atividade física.

7. Inferência de Causalidade e Mudanças Individuais

Não. Os resultados indicam apenas **associação estatística**, e não uma relação de **causa e efeito**.

Justificativa:

- **Estudo Observacional:** O modelo compara pessoas diferentes no mesmo momento. Ele não acompanha a mesma pessoa ao longo do tempo para garantir que a perda/ganho de peso altere sua glicemia na mesma proporção.
- **Confundimento Não Mensurado:** Fatores cruciais como dieta, uso de medicamentos, qualidade do sono e genética não foram considerados no modelo.
- **Interpretação Correta:** O coeficiente reflete a **diferença média entre indivíduos** com IMCs distintos, e não o resultado direto de uma intervenção individual.